

## Pipeline de Ingesta, Procesamiento y Consumo GCP

### Fuentes:

Se escogió la fuente `co_transacciones_habi.csv` porque es la única que contiene transacciones individuales en pesos colombianos y, además, incluye las características de las viviendas (área, alcobas, baños, ciudad y tipo) que se necesitan para responder la pregunta de investigación: ¿Cuánto debería costar una vivienda en Colombia según sus características?

Las demás fuentes se descartaron porque corresponden a otros países o monedas (India y Estados Unidos) y porque están más orientadas a realizar análisis de BI que a entrenar un modelo de ML.

### Pregunta de Investigación:

#### ¿Cuánto debería costar una vivienda en Colombia según sus características?

Esta pregunta tiene sentido porque el negocio principal de Habi es comprar, remodelar y vender viviendas. Si una propiedad se compra por encima de su valor real o se vende por debajo de su precio de mercado, la empresa pierde dinero en cada operación. Por eso, contar con un modelo de ML que estime el precio a partir de características como el área, el número de alcobas, los baños, la ciudad y el tipo de inmueble ayuda a reducir la dependencia de valoraciones manuales o subjetivas y a tomar decisiones de compra y venta de manera más objetiva y consistente.

Además, en Colombia la determinación del valor de un inmueble es un tema complejo y ha generado múltiples discusiones debido a las diferencias entre los avalúos catastrales y los valores comerciales. Esto demuestra que el precio de una vivienda depende de múltiples factores y no únicamente de un avalúo administrativo. En este contexto, un modelo entrenado con transacciones reales puede servir como una herramienta de apoyo para estimar el precio de mercado de forma más precisa y consistente. (ambitojuridico, 2026)

### Conceptos Modelado Por Capas

- **RAW:**

Esta es la primera capa donde llegan los datos tal como vienen de la fuente, sin hacerles ningún cambio. Todas las columnas se guardan como texto (STRING), sin importar si realmente son números, fechas o valores. Además, se agrega una columna llamada **load\_date** para saber cuándo se cargó la

información. El objetivo de esta capa es conservar una copia exacta de los datos originales por si más adelante es necesario revisar de dónde salió un dato o volver a procesarlo.

- **STAGING:**

En esta capa se limpian y organizan los datos para que sean más fáciles de usar. Aquí se convierten los tipos de datos (por ejemplo, de texto a número o fecha), se unifican los nombres de ciudades y tipos de vivienda, se eliminan registros duplicados y se descartan los que no sirven para el análisis, como las viviendas que no tienen precio.

- **CONSUMO:**

Esta es la capa que finalmente usan los analistas o el modelo de Machine Learning. Aquí se crean nuevos datos útiles a partir de los existentes, por ejemplo, el precio por metro cuadrado, el logaritmo del precio o algunas variables relacionadas con la fecha. También se divide la información en datos de entrenamiento y prueba para que el modelo pueda aprender y luego evaluarse siempre de la misma manera. Además, esta es la única capa que tiene un contrato de datos, lo que garantiza que la información cumpla las reglas definidas antes de ser utilizada.

### **Transformaciones Realizadas:**

En la transformación de RAW a STAGING se limpiaron y estandarizaron los datos: se normalizaron ciudades, tipos y estados, se convirtieron los datos a sus tipos correctos, se eliminaron registros sin precio y se quitaron duplicados. Estas reglas se definieron a partir del análisis exploratorio (EDA), donde se identificaron, por ejemplo, 367 registros sin precio, 900 IDs duplicados y ningún error en la conversión de tipos.

Para garantizar que estas transformaciones funcionen correctamente, se implementaron 6 pruebas unitarias, cada una validando una regla identificada durante el EDA.

### **Capa de Consumo:**

La capa de consumo toma los datos ya limpios de stg\_transaccionesabi y genera nuevas variables útiles para el modelo, como el precio por metro cuadrado, el logaritmo del precio y variables de fecha. Luego divide los datos en entrenamiento y test de forma reproducible y genera tres tablas: ml\_features\_transacciones, ml\_train\_transacciones y ml\_test\_transacciones.

Se eligió un modelo de datos relacional (SQL) sobre BigQuery porque la información ya está organizada en tablas y el modelo de Machine Learning necesita ese formato para entrenarse. Usar una base de datos NoSQL solo añadiría complejidad sin aportar beneficios para este caso.

### **Contrato de Datos:**

Se definieron 3 contratos de datos en formato YAML, uno para cada tabla de consumo. Estos contratos se validan automáticamente al final del proceso y, si alguna regla no se cumple, la tarea de Airflow falla y el pipeline se detiene.

El contrato de **ml\_features\_transacciones** valida que existan datos, que el identificador de la propiedad sea único, que no haya valores nulos en las columnas importantes, que los valores permitidos sean correctos, que las coordenadas correspondan a Colombia y que el precio sea mayor a 10 millones de COP para evitar errores de captura. También verifica que la información tenga una antigüedad máxima de 7 días.

Los contratos de **ml\_train\_transacciones** y **ml\_test\_transacciones** aplican las mismas validaciones sobre los datos, pero no incluyen las reglas de frescura ni de división (split), ya que son tablas derivadas de la tabla principal.

### **Análisis del Negocio**

Habi compra casas y apartamentos, los remodela y luego los vende. Para que este negocio sea rentable, es muy importante estimar correctamente el valor de cada inmueble antes de comprarlo y después de remodelarlo. Este proyecto construye un pipeline de datos que reúne la información de las transacciones (ubicación, área, tipo de inmueble, precio, entre otras características), la limpia y la organiza para que un modelo de Machine Learning pueda estimar el precio de una vivienda de forma automática, reduciendo la dependencia de valoraciones manuales.

El modelo con mejor desempeño fue XGBoost, que logra estimar el precio de una vivienda con un margen de error promedio de \$24 millones sobre un valor típico de \$167 millones, lo que equivale a un error aproximado del 15%. Además, explica cerca del 77% de la variación en los precios utilizando variables como la ciudad, el área, el número de habitaciones y baños, el tipo de inmueble y la fecha de la transacción. El 23% restante se debe a factores que no están presentes en el dataset.

## **Referencias**

ambitojuridico. (14 de Abril de 2026). *ambitojuridico*. Obtenido de ambitojuridico:  
<https://www.ambitojuridico.com/noticias/civilfamilia/videocolumna-que-esta-pasando-con-los-avaluos-catastrales-en-colombia>